

АНАЛИЗ ТРЕБОВАНИЙ

Уточняющие вопросы

Бизнес-цели и успех через 3 месяца

1. Что именно считается «работающим результатом» через 3 месяца?

- Демо в лабораторной среде?
- Пилот на 1% трафика с ручным сравнением?
- Или реальный A/B-тест с измеримым ростом конверсии (требует минимум 4–6 недель сбора данных)?

Данные и трекинг

2. Какие сырые события (клики, добавления в корзину, просмотры) и за какой период доступны в вашей внутренней БД?

- Если данных нет (только агрегаты из GA) — готовы ли за 2–3 недели настроить сбор собственных логов через новый трекер?

3. Есть ли единая система идентификации пользователя между онлайн и офлайн?

- Например, по номеру телефона, карте лояльности, email.
- Без этого «омниканальность» из требования нереализуема.

LLM и генеративные описания

4. Что важнее для первых версий: скорость отклика (200 мс) или генеративные объяснения от LLM?

- LLM даже локально даёт минимум 300–1000 мс.
- Готовы ли вы к асинхронной подгрузке объяснений (блок рендерится через 1–2 секунды)?

5. Какую схему безопасности данных по LLM утверждаем?

- Локальная модель требует GPU-серверов -> согласование 2 месяца + дорого на старте.
- Закрытое API быстрее, но дороже на дистанции.

АНАЛИЗ ТРЕБОВАНИЙ

Уточняющие вопросы

Технические ограничения

6. Готовы ли вы выделить небольшой сегмент трафика для A/B-теста?

– Без рандомизированного контроля доказать рост конверсии невозможно.

7. Какие 2–3 категории товаров самые критичные для кросс-продаж?

– PoC не должен охватывать все 50 000 SKU. Предлагаем начать с «ноутбуки + аксессуары» и «телевизоры + саундбары».

8. Как часто обновляются данные в 1С и какова задержка?

– Сейчас раз в 15 минут. Для batch-рекомендаций ОК, для real-time — нет.

Организационные

9. Кто будет принимать решение Go/No-Go после PoC?

– Нужен один ответственный (CEO или CTO), иначе проект зависнет между двумя подходами.

10. Есть ли у вас бюджет на GPU-серверы, если PoC докажет эффективность?

– Если нет, мы сразу проектируем решение под облако с возможностью миграции on-premise.

ВЫБОР МОДЕЛИ КОНТРАКТА

Этап	Модель контракта	Клиент	Исполнитель
PoC	Capped T&M (лимит бюджета, например, 3 млн ₽, почасовая оплата)	Не переплачивает, если проект не взлетит. Видит цену «потолка».	Компенсация за уточнение требований и работу с «грязными» данными.
MVP	T&M на ML-фичи + Fixed Price на интеграцию с Bitrix и прочие понятные вещи	Твёрдая цена за понятную часть (API, загрузки). Гибкость там, где эксперимент.	Не сидим на голом FP, когда начинаются эксперименты.
Production	T&M + SLA с фиксом на поддержку инфраструктуры (GPU, Redis, мониторинг) и ПО.	Платит за реальную нагрузку и поддержку. Может масштабировать и развивать систему.	Предсказуемые доходы от поддержки, развитие новых фич.

МАТРИЦА РИСКОВ

	Среднее воздействие	Высокое воздействие	Высокое воздействие
Низкая вероятность		Непредсказуемый рост расходов на токены	
Средняя вероятность		Дрейф модели после масштабирования	Утечка ПДн в публичную LLM
Средняя вероятность	Сопротивление СТО и РНР-команды	Модель не лучше rule-based	Галлюцинации LLM
Высокая вероятность		Нет сырых данных кликов (только GA)	Latency > 200 мс (ML + LLM)

МАТРИЦА РИСКОВ

№	Риск	Вероят-ность	Влияние	Митигация
1	Нет сырых данных кликов (только GA)	Высокая	Критическое	РoC: сразу проверяем качество данных. Если нет -> не стартуем. Временно используем заказы + правило «этот товар смотрели вместе». Запретить генерацию фактов о товарах. LLM только перефразирует шаблоны: «К ноутбуку X подойдут мышки Y». Факты — из каталога.
2	Галлюцинации LLM	Средняя	Высокое	Разделить: быстрая рекомендация под 50 мс. LLM-объяснения — через lazy loading или кеш.
3	Latency > 200 мс (ML + LLM)	Высокая	Высокое (СТО заблокирует)	РoC: чёткий критерий — ML лучше baseline на $\geq 20\%$. Если нет — честное No-Go.
4	Модель не лучше rule-based	Средняя	Критическое (проект закроют)	

МАТРИЦА РИСКОВ

№	Риск	Вероят-ность	Влияние	Митигация
5	Соппротивление СТО	Средняя	Среднее	Архитектура «чёрный ящик»: рекомендации через отдельный API. Bitrix только делает вызов. СТО не трогает монолит.
6	Утечка ПДн в публичную LLM	Средняя	Критическое	Только on-Prem модели для контура с ПДн. Обезличивание данных.
7	Дрейф модели после масштабирования	Средняя	Высокое	Автоматическое переобучение раз в месяц + мониторинг метрик. Откат на предыдущую версию.
8	Непредсказуемый рост расходов на токены	Низкая	Среднее	Выбор тарифа с жёстким лимитом токенов в месяц. Кеширование генераций на уровне приложения. Мониторинг и алертинг расхода токенов

ROADMAP

Этап PoC

Цель: понять, даёт ли ML сигнал, оценить data gaps и latency.

Scope	Риски	Критерии успеха
- Загружаем историю заказов и кликов (если есть) из 1С и GA. - Только ML - берём старую систему правил как отправную точку, и AI-based, чтобы сравнить — даёт ли AI хоть какой-то прирост точности на исторических примерах Не делаем - CI/CD - Безопасность - LLM	- Интеграция с сайтом - Нет данных кликов -> вместо них используем только заказы (менее точная модель).	- Понятен список data gaps (чего не хватает для MVP). - Оценена latency модели (должна укладываться в ну пусть 50 мс без LLM). - Выбраны технологии - Подготовлен Golden Dataset Решение: Go/No-Go

ROADMAP

Этап MVP

Цель: получить первые бизнес-метрики на реальных пользователях.

Scope	Риски	Критерии успеха
• Один сценарий для нескольких видов товаров (например, блок «С этим товаром часто покупают» на карточке товара). • Ограниченное количество магазинов + онлайн на 5% трафика. • Реальные данные (batch каждые 15 минут из 1С и логов кликов). • Логирование решений и A/B-тест. • Базовый мониторинг (модель не дрейфует). • Документация Не делаем • LLM-описания • Омниканальность (офлайн-покупки) • Масштабирование на всю сеть	• Пользователи не замечают рекомендации или они раздражают. • Модель хорошая, но latency на реальных данных проседает.	• Бизнес: конверсия блока рекомендаций, например, > 1.5% (рост в 3×). • Продукт: пользователи кликают на рекомендации хотя бы в 1% сессий. • Технические: latency рекомендаций < 200 мс (p95). • A/B-тест показывает статистически значимый рост AOV на 5% (до целевых 10%). Решение: Go/No-Go

ROADMAP

Этап Production

Цель: встроить в core-процессы, добавить LLM и омниканальность, обеспечить SLA.

Scope	Риски	Критерии успеха
• Real-time рекомендации (при каждом просмотре товара). • Полная омниканальность (офлайн-покупки не дублируются). • CI/CD для моделей. • автоматическое переобучение ML раз месяц, например. • Добавляем LLM для генерации объяснений (локальная модель). • Push-уведомления с AI-рекомендациями. • Документация	• LLM замедляет API или начинает галлюцинировать. • Дрейф модели после масштабирования • Рост нагрузки на Bitrix (СТО прав).	• Технические: рекомендации за <200 мс p95, LLM-объяснения — асинхронно (не блокируют рендер). • Бизнес: рост AOV на 10%, расходы на модель в ожидаемых рамках • ML: модель переобучается автоматически, метрики не падают. • Безопасность: все данные локально, аудит пройден.